



BOOK FINDER

UTILIZZO DI TECNICHE DI NLP
PER L'ANALISI DELLE TRAME
DEI LIBRI




PRE PROCESSING

DATASET ORIGINARIO

Wikipedia_article_ID	Freebase_ID	Book_title	Author	Publication_date	Book_genres	Plot_summary
0	620	/m/0hhy	Animal Farm	George Orwell	1945-08-17	{"/m/016lj8": "Roman \u00e0 clef", "/m/06nbt": "....", "/m/06n90": "Science Fiction", "/m/0l67h": "N..."}, "Old Major, the old boar on the Manor Farm, ca...
1	843	/m/0k36	A Clockwork Orange	Anthony Burgess	1962	{"/m/06n90": "Science Fiction", "/m/0l67h": "N..."}, "Alex, a teenager living in near-future Englan...
2	986	/m/0ldx	The Plague	Albert Camus	1947	{"/m/02m4t": "Existentialism", "/m/02xlf": "Fi..."}, "The text of The Plague is divided into five p...
3	1756	/m/0swv	An Enquiry Concerning Human Understanding	David Hume	NaN	NaN, "The argument of the Enquiry proceeds by a ser...
4	2080	/m/0wkt	A Fire Upon the Deep	Vernor Vinge	NaN	{"/m/03lrw": "Hard science fiction", "/m/06n90..."}, "The novel posits that space around the Milky ...
...	...	...	...	...	...	...

DATASET PRE PROCESSATO

	Book_title	Author	Publication_date	Book_genres	Plot_summary	clear_text
0	Animal Farm	George Orwell	1945-08-17	[Roman à clef, Satire, Children's literature, ...	Old Major, the old boar on the Manor Farm, ca...	[old, major, old, boar, manor, farm, call, ani...
1	A Clockwork Orange	Anthony Burgess	1962	[Science Fiction, Novella, Speculative fiction...	Alex, a teenager living in near-future Englan...	[alex, teenag_live, near_futur, england, lead,...
2	The Plague	Albert Camus	1947	[Existentialism, Fiction, Absurdist fiction, N...	The text of The Plague is divided into five p...	[text, plagu, divid_five, part_town, oran, tho...
3	An Enquiry Concerning Human Understanding	David Hume	Unknown	[Unknown]	The argument of the Enquiry proceeds by a ser...	[argument, enquiri, proce, seri, increment, st...
4	A Fire Upon the Deep	Vernor Vinge	Unknown	[Hard science fiction, Science Fiction, Specul...	The novel posits that space around the Milky ...	[novel, posit, space, around, milki_way, divid...
...	...	...	...	...	...	...



Il **Pre Processing** è la preparazione dei testi per successive elaborazioni e queste sono le tecniche di pulizia che abbiamo utilizzato:

- **Tokenizzazione:** suddivisione del testo in singole parole (tokens).
- **Lower Case:** riscrivere ogni token senza maiuscole.
- **Stop words:** elimina tutte le parole tipiche della lingua che risultano ridondanti e inutili al significato (articoli, preposizioni, congiunzioni, verbi ausiliari e modali).
- **Stemming:** operazione per ridurre le parole alla loro radice.
- **Lemmatizzazione:** riduce parole alla propria forma canonica (lemma).
- **N-Grams:** tecnica per considerare non solo le parole ma anche le n precedenti. (noi abbiamo utilizzato i bi-grams)

Quelli descritti sopra sono concetti chiave nel campo del **NLP (Natural Language Processing)**, che è una branca dell'intelligenza artificiale che si occupa della comprensione e dell'elaborazione del linguaggio naturale da parte dei computer. Coinvolge una serie di tecniche e algoritmi per consentire ai computer di interagire e comprendere il linguaggio umano in modo efficace.


EFFICIENZA DELLA PULIZIA DEI TESTI

	len_parole	len_parole_stop	len_parole_lemma	len_parole_ngram
count	16559.000000	16559.000000	16559.000000	16559.000000
mean	437.575518	233.557944	232.802645	194.344163
std	509.715570	266.791564	265.809542	223.787884
min	1.000000	1.000000	1.000000	1.000000
25%	123.000000	67.000000	67.000000	55.000000
50%	269.000000	145.000000	144.000000	120.000000
75%	578.500000	310.000000	309.000000	258.000000
max	10514.000000	5060.000000	5051.000000	4135.000000

Si possono notare le differenze di lunghezza delle trame dopo ogni passaggio del pre processing, fino ad arrivare ad una pulizia completa che aiuta molto nelle elaborazioni future.



TOPIC MODELING



La **Topic Modeling** analizza la distribuzione delle parole all'interno del corpus di testo e identifica i gruppi di parole che compaiono insieme con maggiore frequenza, ovvero i "topic". Un topic può essere definito come un insieme di parole correlate che rappresentano un determinato argomento o tema all'interno del corpus.


La Topic Modeling si basa su algoritmi di apprendimento automatico non supervisionato, nel nostro caso abbiamo utilizzato il **Latent Dirichlet Allocation (LDA)**, che assegna a ciascun documento del corpus una distribuzione di probabilità sui vari topic, e assegna a ciascuna parola una distribuzione di probabilità sui vari topic. In questo modo, è possibile identificare i topic principali del corpus e valutare l'importanza di ciascun topic all'interno del corpus.

Per capire quali siano i valori più significativi dei nostri iperparametri abbiamo effettuato una grid search da 1 a 25 topic.

La **grid search** consiste nel creare una "griglia" di tutti i possibili valori dei parametri del modello e si esegue l'addestramento e la valutazione del modello per ogni combinazione di parametri nella griglia

Il modello è stato valutato secondo la Coherence; abbiamo utilizzato il modello con 22 topic, alpha 'asymmetric', beta pari a 0.31 e 10 iterazioni.

RISULTATI GRID SEARCH



Topics	
2	0.260786
3	0.289832
4	0.296646
5	0.314562
6	0.342662
7	0.446660
8	0.458193
9	0.469665
10	0.476905
11	0.242873
12	0.240637
13	0.256350
14	0.238698
15	0.243934
16	0.263837
17	0.259421
18	0.252357
19	0.257129
21	0.534744
22	0.554856
23	0.540037
24	0.526734

Il grafico riporta i Coherence score ottenuti dal param-grid. Per ogni numero di topic avevamo diverse configurazioni di parametri con differenti valori di Coherence. Qui sono riportati i valori di Coherence maggiori relativi alla migliore configurazione per numero di topic.

```
best_topic = df.groupby('topics').coherence_score.max()
```

MODELLO LDA

	text	best_topic	rilevance	topic_words
0	old major old boar manor farm call anim_farm m...	0	0.395515	[(stori, 0.0021984065), (famili, 0.0021902695)...
1	alex teenag_live near_futur england lead gang ...	0	0.577599	[(stori, 0.0021984065), (famili, 0.0021902695)...
2	text plagu divid_five part_town oran thousand ...	0	0.375041	[(stori, 0.0021984065), (famili, 0.0021902695)...
3	argument enquiri proce seri increment step sep...	12	0.683029	[(christian, 0.0035712735), (argu, 0.003057414...
4	novel posit space around milki_way divid conce...	3	0.924069	[(ship, 0.0026267683), (use, 0.002313784), (hu...
...	...	...	...	...
16554	prue mckeel rescu brother dowag gover conclus ...	6	0.615961	[(find, 0.0028442382), (kill, 0.0027477066), (...]
16555	reader_first meet rapp covert_oper iran discov...	3	0.932649	[(ship, 0.0026267683), (use, 0.002313784), (hu...
16556	book_follow rough chronolog_order switch curre...	0	0.992914	[(stori, 0.0021984065), (famili, 0.0021902695)...
16557	colbert address topic_includ wall_street campa...	3	0.652549	[(ship, 0.0026267683), (use, 0.002313784), (hu...
16558	makar devushkin varvara dobroselova second_cou...	0	0.996525	[(stori, 0.0021984065), (famili, 0.0021902695)...

Coherence Score: 0.47745616218571346

A questo punto runniamo il modello con 22 topic, alpha='asymmetric' e beta=0.3 I.


Successivamente associamo ad ogni testo il topic più rilevante.

Calcoliamo la coerenza del modello con il metodo c_v e passiamo al grafico multidimensionale della libreria PyLDavis.

Infine aggiungiamo a questo dataframe le colonne del titolo, del genere, dell'autore e della data di pubblicazione di ogni libro.




DISTRIBUZIONE DEI TOPIC





WORD EMBEDDING



Il **Word Embedding** (rappresentazione distribuita delle parole) permette di memorizzare le informazioni sia semantiche che sintattiche delle parole partendo da un corpus non annotato e costruendo uno spazio vettoriale in cui i vettori delle parole sono più vicini se le parole occorrono negli stessi contesti linguistici, cioè se sono riconosciute come semanticamente più simili; in altre parole, il word embedding rappresenta le parole come vettori numerici in modo che parole simili siano più vicine tra loro nello spazio vettoriale.

Integrare i word embedding nel processo di raccomandazione basato sui topic può portare a raccomandazioni più precise e rilevanti, ma soprattutto ad una riduzione significativa del tempo computazionale.

Nel nostro progetto, abbiamo utilizzato il vettorizzatore **TF-IDF (Term Frequency-Inverse Document Frequency)** per calcolare la similarità tra una frase di input dell'utente e una collezione di libri. Il TF-IDF è una tecnica che assegna un punteggio a ciascuna parola in base alla sua importanza all'interno del testo e all'importanza relativa rispetto all'intera collezione di testi.

VECTORIZE

Per prima cosa andiamo a vettorizzare il **corpus**, ottenendo una **matrice** composta da vettori riga contenenti i **punteggi** per ciascuna parola.

Si fa lo stesso con la **frase inserita** come input


	Document 1	Document 2	Document 3	Document 4
Word 1	0.85	0	0.3	0
Word 2	0.34	0.12	0	0.66
Word 3	0	0.73	0.12	0
Word 4	0.25	0	0.24	0.56
Word 5	0	0.54	0.2	0.49

Word embedding

TF-IDF

COSINE SIMILARITY

Per ottenere la distanza, tra il vettore frase di input e tutte le righe della matrice, abbiamo usato la distanza coseno.



La formula è la seguente:

$$\text{Similarity} = \cos(\theta) = \frac{A \cdot B}{||A|| \cdot ||B||} = \frac{\sum_i^n A_i B_i}{\sqrt{\sum_i^n A_i^2} \sqrt{\sum_i^n B_i^2}}$$

PROGRAMMA FINALE

Il programma consiglia libri da una descrizione data in input dall'utente, ma mancava ancora qualcosa, così abbiamo deciso di implementare ulteriormente Book Finder inserendo un'altra opzione: poter inserire un titolo di un libro per farsi consigliare un numero desiderato di libri simili.

Cosa vuoi fare?

Premere 1 se vuoi trovare un libro utilizzando una breve descrizione
Premere 2 se vuoi trovare un libro partendo dal titolo

Premere 1 se vuoi trovare un libro utilizzando una breve descrizione
Premere 2 se vuoi trovare un libro partendo dal titolo
Cosa vuoi fare? 1
Scrivi la descrizione: A fantastic story about magic rings that empower the wearer
Inserisci il numero di libri simili che vuoi cercare: 5
Id_topic più probabile è: 5
Con probabilità: 0.6279852390289307

	Book_title	Author	Publication_date	Book_genres	Plot_summary
8057	Expecting Someone Taller	Tom Holt	1987	['Satire', 'Fantasy', 'Speculative fiction', '...	The story involves Malcolm Fisher, a hapless ...
15275	The Fellowship of the Ring	J. R. R. Tolkien	1954-07-24	['Fantasy', 'Autobiography', 'Biography', 'Ref...	The Prologue is meant partly to help people w...
78	The Lord of the Rings	J. R. R. Tolkien	Unknown	['Adventure novel', 'Speculative fiction', 'Fa...	Long before the events of the novel, the Dark...
9933	The Lord of the Rings	Shaun McKenna	Unknown	['Unknown']	The half-Elven maiden Arwen sings the prologu...
4359	The Enchanted Castle	E. Nesbit	1907	['Children's literature', 'Fantasy', 'Speculat...	The enchanted castle of the title is a countr...

In questo caso scegliendo di dare in input una descrizione, il programma ci consiglia un numero da noi richiesto (5 nell'esempio) di libri che si rifanno a quella descrizione.

Premere 1 se vuoi trovare un libro utilizzando una breve descrizione
Premere 2 se vuoi trovare un libro partendo dal titolo
Cosa vuoi fare? 2
Scrivi il titolo del libro: The Lord of the Rings
Inserisci il numero di libri simili che vuoi cercare: 5
Libro trovato, ne cerco altri simili...
Id_topic più probabile è: 5
Con probabilità: 0.5729590654373169
[5, 0.5729590654373169]

	Book_title	Author	Publication_date	Book_genres	Plot_summary
15275	The Fellowship of the Ring	J. R. R. Tolkien	1954-07-24	['Fantasy', 'Autobiography', 'Biography', 'Ref...	The Prologue is meant partly to help people w...
8057	Expecting Someone Taller	Tom Holt	1987	['Satire', 'Fantasy', 'Speculative fiction', '...	The story involves Malcolm Fisher, a hapless ...
249	The Return of the King	J. R. R. Tolkien	1955-10-20	['Science Fiction', 'Biography', 'Speculative ...	Gandalf and Pippin arrive at Minas Tirith in ...
248	The Two Towers	J. R. R. Tolkien	1954-11-11	['Science Fiction', "Children's literature", '...	As Aragorn searches for Frodo, he suddenly he...
2811	Heir Apparent	Vivian Vande Velde	2002	['Science Fiction', 'Speculative fiction', 'Fa...	Giannine receives a gift certificate for a Ra...

Ora invece, si è scelto di dare in input il titolo di un libro e il programma consiglia 5 libri simili a quello da noi inserito.

FONTI

SITI WEB

- [Dataset](#)
- [LDA](#)
- [Gensim](#)

LIBRERIE

- Pandas
- Numpy
- pyLDAvis
- Nltk
- Gensim
- Tensorflow
- Sklearn
- Seaborn